

# 数学基础班第 4 课课件：参数估计

管枫

七月在线

July, 2016

# 主要内容

- 点估计
  - 矩估计
  - 极大似然估计
  - 点估计的评判准则
- 区间估计
  - 置信区间

本次课程参考中科大统计系张卫平老师的课程材料:

[http://staff.ustc.edu.cn/~zwp/teach/Math-Stat/,lec\(14,15\)](http://staff.ustc.edu.cn/~zwp/teach/Math-Stat/,lec(14,15))

[http://staff.ustc.edu.cn/~zwp/teach/Prob-Stat/,lec\(4,5,6,7,8\)](http://staff.ustc.edu.cn/~zwp/teach/Prob-Stat/,lec(4,5,6,7,8))

- 本节课常用数学记号

$\mathbb{R}^n$  实坐标空间

$f(x)$  函数

$\int_a^b f(x)dx$  函数积分

$X$  随机变量

$E(X)$  随机变量的期望

$Var(x)$  随机变量的方差

$\alpha_n(x)$  随机变量的  $n$  阶原点矩

$\mu_n(x)$  随机变量的  $n$  阶中心矩

## 参数估计问题

- 已知一个随机变量的分布函数  $X f_{\theta}(x)$ , 其中  $\theta = (\theta_1, \dots, \theta_k)$  为未知参数.
- 样本  $X_1, \dots, X_n$
- 利用样本对参数  $\theta$  做出估计, 或者估计  $\theta$  的某个函数  $g(\theta)$ 
  - 点估计: 用样本的一个函数  $T(X_1, \dots, X_n)$  去估计  $g(\theta)$
  - 区间估计: 用一个区间去估计  $g(\theta)$

# 点估计：矩估计

## 矩估计

- 矩估计法的基本思想是根据大数定律，利用样本矩对总体分布矩进行估计.
- 然后利用总体矩与参数的关系来对参数进行估计.

记号:

样本  $k$  阶矩: 
$$a_k(X) = \frac{1}{n} \sum_{i=1}^n X_i^k \quad m_k(X) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

总体  $k$  阶矩: 
$$\alpha_k(X) = E(X^k) \quad \mu_k(X) = E((X - E(X))^k)$$

# 点估计：矩估计

## 矩估计的基本原理：大数定律

根据大数定律我们知道, 对于任何随机变量  $X$ , 当样本数  $n \rightarrow \infty$  时,  $\frac{1}{n} \sum_{i=1}^n X_i$  收敛于  $E(X)$ . 所以

$$a_1(X) \rightarrow \alpha_1(X)$$

对于任意的  $k$  阶矩, 令  $Y = X^k$ , 那么  $Y$  也是一个随机变量, 所以同样满足大数定律, 于是

$$a_k(X) = a_1(Y) \rightarrow \alpha_1(Y) = \alpha_k(X)$$

而中心矩都可以表示成原点矩的多项式, 所以我们同样有

$$m_k(X) \rightarrow \mu_k(X)$$

# 点估计：矩估计

## Example (两点分布的参数估计)

$X$  服从两点分布取值为  $\{-1, 1\}$ ,  $P(-1) = 1 - \theta$ ,  $P(1) = \theta$ . 现在独立重复实验  $n$  次, 得到样本  $X_1, \dots, X_n$ . 请利用矩估计来估计参数  $\theta$ .

首先考虑哪一个矩可以用来估计参数  $\theta$ . 对于两点分布来说

$$E(X) = (1 - \theta) \cdot (-1) + \theta \cdot 1 = 2\theta - 1$$

$$E(X^2) = (1 - \theta) \cdot 1 + \theta \cdot 1 = 1$$

我们看到一阶矩  $E(X)$  与  $\theta$  有简单直接的关系  $\theta = \frac{1+E(X)}{2}$   
所以我们使用一阶样本矩估计. 得到一个参数估计量  $\hat{\theta} = \frac{1+\bar{X}}{2}$ .

# 点估计：矩估计

## Example (正态分布的参数估计)

$X$  服从参数为  $\theta = (\mu, \sigma)$  的正态分布，独立重复实验  $n$  次得到样本  $X_1, \dots, X_n$ . 请利用矩估计来估计参数  $\theta$ .

首先考虑哪一个矩可以用来估计参数  $\theta$ . 对于正态分布来说

$$\begin{aligned}E(X) &= \mu \\E(X^2) &= \mu^2 + \sigma^2 \\E(X^3) &= \frac{1}{6}(3\mu\sigma^2 + \mu^3)\end{aligned}$$

原则上 2 阶矩和 3 阶矩都可以用来估计  $\sigma^2$ ，所以矩估计一般来讲是不唯一的。当有多种选择的时候，我们尽可能选择阶数较小的矩。所以可以采用

$$\hat{\mu} = a_1(X), \hat{\sigma}^2 = m_2(X).$$

此处对  $\sigma$  的估计并不是最优的，在点估计的评判标准那一节，我们进行更细致的讨论。



# 点估计：极大似然估计

## 极大似然估计

- 给定随机变量的分布与未知参数，利用观测到的样本计算似然函数
- 选择最大化似然函数的参数作为参数估计量.

# 点估计：极大似然估计

## 极大似然估计基本原理：最大化似然函数

假设样本  $\{X_1, \dots, X_n\}$  服从概率密度函数  $f_\theta(x)$ . 其中  $\theta = (\theta_1, \dots, \theta_k)$  是未知参数.

当固定  $x$  的时候,  $f_\theta(x)$  就是  $\theta$  的函数, 我们把这个函数称为似然函数, 记为  $L_x(\theta)$  或  $L(\theta)$ .

似然函数不是概率, 但是很类似于概率. 当  $\theta$  给定的时候, 它是概率密度. 当  $x$  给定,  $\theta$  变化的时候, 他就类似于在表示, 在这个观测量  $x$  的条件下, 参数等于  $\theta$  的可能性 (不是概率). 起个名字叫做似然函数.

# 点估计：极大似然估计

## 极大似然估计基本原理：最大化似然函数

假设  $x = (x_1, \dots, x_n)$  是样本的观测值. 那么整个样本的似然函数就是

$$L_x(\theta) = \prod_{i=1}^n L_{x_i}(\theta)$$

这是一个关于  $\theta$  的函数, 选取使得  $L_x(\theta)$  最大化的  $\hat{\theta}$  作为  $\theta$  的估计量.

最大化似然函数  $\theta$ , 相当于最大化似然函数的对数

$l_x(\theta) = \ln(L_x(\theta))$ . 一般我们求解似然函数或者对数似然函数的驻点方程

$$\frac{dl(\theta)}{d\theta} = 0, (\text{或者 } \frac{dL(\theta)}{d\theta} = 0)$$

然后判断整个驻点是否最大点.(求驻点可以用牛顿法, 或者梯度法等等)

# 点估计：极大似然估计

## Example (正态分布的参数估计)

$X$  服从参数为  $\theta = (\mu, \sigma)$  的正态分布，独立重复实验  $n$  次得到样本  $X_1, \dots, X_n$ . 请利用极大似然估计来估计参数  $\theta$ .

$$L(\mu, \sigma) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

$$l(\mu, \sigma) = C - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2} \ln(\sigma^2)$$

所以似然方程为  $\frac{\partial l}{\partial \sigma} = \frac{\partial l}{\partial \mu} = 0$ , 也就是

$$a = \frac{1}{n} \sum_{i=1}^n x_i$$
$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - a)^2$$

因此得到极大似然估计量

$$\hat{a} = \overline{X}$$
$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \overline{X})^2$$

# 点估计：点估计的评判准则

- 相合性 (consistency): 当样本数量趋于无穷时, 估计量收敛于参数真实值.
- 无偏性 (bias): 对于有限的样本, 估计量所符合的分布之期望等于参数真实值.
- 有效性 (efficiency): 估计值所满足的分布方差越小越好.
- 渐进正态性 (asymptotic normality): 当样本趋于无穷时, 去中心化去量纲化的估计量符合标准正态分布.

# 点估计：相合性

## 相合性

相合性是最基本的要求，矩估计的相合型是由大数定律来保证的。极大似然估计的相合型也是隐含的由大数定律来保证的

假设一个随机变量  $X$  服从  $f_{\theta_0}(x)$ . 最大化  $l_x(\theta)$  跟最大化  $\frac{1}{n}l_x(\theta)$  是一样的

$$\begin{aligned}\frac{1}{n}l_x(\theta) &= \frac{1}{n} \sum_{i=1}^n l_{x_i}(\theta) \\ &= \frac{1}{n} \sum_{i=1}^n \ln(f_{\theta}(x_i))\end{aligned}$$

这个无穷求和就收敛于（大数定律）

$$E(\ln(f_{\theta}(X))) = \int_x \ln(f_{\theta}(x)) f_{\theta_0}(x) dx$$

## 点估计：相合性

而  $\hat{\theta}$  是  $\frac{1}{n}l_x(\theta)$  的极大值点, 所以  $\lim \hat{\theta}$  收敛于  $E(\ln(f_\theta(X)))$  的极大值点。

所以我们只需要证明  $\theta_0$  确实是  $E(\ln(f_\theta(X)))$  的极大值点. 因为  $\ln(x)$  是个凹函数, 根据琴生不等式我们有

$$\begin{aligned} & \int_x \ln(f_\theta(x)) f_{\theta_0}(x) dx - \int_x \ln(f_{\theta_0}(x)) f_{\theta_0}(x) dx \\ &= \int_x \ln(f_\theta(x)/f_{\theta_0}(x)) f_{\theta_0}(x) dx \\ &\leq \ln\left(\int_x \frac{f_\theta(x)}{f_{\theta_0}(x)} f_{\theta_0}(x) dx\right) \\ &= \ln\left(\int_x f_\theta(x) dx\right) \\ &= \ln(1) = 0 \end{aligned}$$



# 点估计：相合性

也就是说

$$E(\ln(f_{\theta}(X))) - E(\ln(f_{\theta_0}(X))) \leq 0$$

于是  $\theta_0$  就是关于  $\theta$  的函数  $E(\ln(f_{\theta}(X)))$  的极大值点.

# 点估计：无偏性

## 无偏性

任何一个满足相合性的参数估计，当样本趋于无穷的时候都会收敛与参数的真实值. 但是对于有限样本的情况下，这个估计值的期望不见得总等于参数的真实值.

比如我们做的关于正态分布的方差的估计  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2$ .

我们计算一下等式右边的期望值

# 点估计：无偏性

$$\begin{aligned} E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu + \mu - \bar{X})^2\right) \\ &= E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2\right) - E((\mu - \bar{X})^2) \\ &= E((X_i - \mu)^2) - E((\mu - \bar{X})^2) \\ &= \sigma^2 + \text{Var}(\bar{X}) \\ &\geq \sigma^2. \end{aligned}$$

所以我们倾向于“低估”  $\sigma^2$ . 那么我们低估的这个值  $\text{Var}(\bar{X})$  等于多少呢?

# 点估计：无偏性

令  $Y_i = X_i - \mu$ , 那么  $\bar{X} - \mu = \bar{Y}$ , 所以

$$E((\mu - \bar{X})^2) = E((\bar{Y})^2)$$

$Y$  的特征函数是  $\phi_Y(t) = e^{-\frac{t^2\sigma^2}{2}}$ , 所以

$$\begin{aligned}\phi_{\bar{Y}}(t) &= (e^{-\frac{t^2\sigma^2}{2n^2}})^n \\ &= e^{-\frac{t^2(\sigma)^2/\sqrt{n}}{2}}\end{aligned}$$

于是  $Var(\bar{X}) = Var(\bar{Y}) = \sigma^2/n$ . 所以

$$E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \frac{n-1}{n} \sigma^2$$

因此  $\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  才是  $\sigma^2$  的无偏估计量.

# 点估计：有效性

## 有效性

如果两个参数估计量  $\hat{\theta}$  和  $\tilde{\theta}$ ，既是相合的又是无偏的，那么他们两个中方差较小的那一个比较好。如果

$$\text{Var}(\hat{\theta}) \geq \text{Var}(\tilde{\theta})$$

那么我们就认为  $\tilde{\theta}$  比较有效。

此处举一个例子。

# 点估计：渐进正态性

## 渐进正态性

渐进正态这里涉及到一些矩阵的知识, 尤其是极大似然估计的渐进正态性质. 等讲完线性代数, 在作为一个例子扩展讲解一下。

# 区间估计：置信区间

## 置信区间

置信区间可以认为是点估计的一个扩展。分为如下步骤

- 找到一个点估计  $T$
- 找出一个  $T$  与  $\theta$  的函数满足某一个已知的分布  $F$
- 利用这个已知的分布  $F$  的  $\alpha/2$  分位数，来求出参数的置信区间。

如果这个分布  $F$  很难找到，那么还有一种近似的方法

- 找到一个点估计  $T$
- 利用渐进正态的性质，发现  $T$  在  $n$  很大的时候满足某种正态分布。
- 利用这个已知的正态分布的  $\alpha/2$  分位数，来求出参数的置信区间。

# 谢谢大家!